

《未知环境下基于强化学习的无人机端到端目标追踪技术研究》论文大纲

目录

一、 摘要

二、 关键词

三、 1. 引言

1.1 研究背景与意义

1.2 研究现状与挑战

1.3 研究内容与贡献

1.4 论文结构安排

四、 2. 相关工作综述

2.1 无人机目标检测与跟踪技术综述

2.2 未知环境下的目标搜索策略

2.3 强化学习在无人机控制中的应用

五、 3. 未知环境下无人机目标搜索策略

3.1 基于信号检测的目标先验信息获取

3.2 基于先验信息的目标搜索方法

3.3 目标检测与锁定

六、 4. 基于强化学习的端到端目标追踪方法

4.1 强化学习基础与无人机控制框架

4.2 端到端强化学习跟踪模型设计

4.3 策略网络与价值网络设计

4.4 训练方法与算法优化

七、 5. 系统实现与实验验证

5.1 系统架构与实现细节

5.2 实验环境与数据集

5.3 性能评估指标

5.4 实验结果分析

八、 6. 结论与展望

6.1 研究工作总结

6.2 未来研究方向

● 摘要

随着无人机（UAV）技术的快速发展，其在目标追踪领域的应用日益广泛。然而，在未知复杂环境下，由于目标位置不可知，无人机首先需要对目标进行搜索定位，然后才能开展精确追踪。针对这一挑战，本文提出了一种**基于强化学习的端到端无人机目标追踪方法**。该方法利用目标携带的信号装置作为先验信息，通过无人机搭载的传感器检测信号以确定目标的大致方位，并据此采用传统搜索策略对目标进行初步定位。一旦目标被成功发现并锁定，系统即切换到基于强化学习的端到端追踪模式，实现对目标的持续精确跟踪。仿真与实验结果表明，与现有方法相比，所提出的两阶段方法在目标搜索效率、定位精度以及跟踪稳定性方面均具有显著优势，能够有效提升无人机在未知环境下执行目标追踪任务的成功率和鲁棒性。

● 关键词

无人机；目标搜索；目标追踪；强化学习；端到端控制；未知环境

1.1 研究背景与意义

近年来，无人机技术因其灵活性高、成本效益好等优势，在军事侦察、环境监测、农业植保、物流配送等众多领域展现出巨大应用潜力。其中，**无人机目标追踪技术**作为无人机自主执行任务的关键能力之一，正成为研究热点。目标追踪技术能够使无人机在复杂环境下持续锁定并跟踪移动目标，对于提升任务执行效率和安全性具有重要意义。例如，在搜救任务中，无人机需要对目标进行持续跟踪以提供实时位置信息；在军事侦察中，无人机需跟踪移动目标以获取情报。因此，研究未知环境下无人机自主追踪技术具有重要的学术价值和现实意义。

1.2 研究现状与挑战

当前，无人机目标追踪技术主要面临**未知环境**和**目标动态**两大挑战。首先，在许多应用场景下，无人机对目标的初始位置并不知情，需要先进行搜索定位。传统的目标搜索方法依赖于预编程的路径规划或基于概率图的搜索策略，但在复杂且动态变化的环境中，这些方法往往难以兼顾搜索效率和准确性。其次，一旦发现目标，无人机需要对移动目标进行持续跟踪。早期研究多采用基于计算机视觉的目标跟踪算法，如光流法、卡尔曼滤波、相关滤波等，这些方法在一定条件下能够实现目标跟踪，但在目标遮挡、快速运动、光照变化等复杂场景下容易出现跟踪丢失或漂移。近年来，随着深度学习的发展，基于卷积神经网络（CNN）的跟踪算法在目标特征提取和鲁棒性方面取得了显著进步。例如，孪生网络（Siamese Network）等深度学习模型通过端到端训练，使无人机直接从原始图像学习目标特征并预测目标位置，显著提高了跟踪精度和适应性。然而，这些传统方法大多将检测与跟踪分为两个独立阶段，缺乏端到端的优化，难以充分挖掘传感器数据与控制策略之间的内在关联。

针对未知环境下的目标搜索与跟踪，多无人机协同搜索也逐渐成为研究重点。无人机集群通过多机协作，可以更高效地覆盖广阔区域，提高目标发现概率。例如，有研究利用多智能体强化学习（MARL）实现无人机集群的协同搜索，通过集中训练-分布式执行的方式，使多架无人机在大规模未知环境中协同决策，避免重复搜索并更快定位目标。这些方法虽然提升了搜索效率，但如何将**搜索阶段与跟**

踪阶段有机融合，实现从粗略定位到精确跟踪的无缝切换，仍是亟待解决的问题。

1.3 研究内容与贡献

本文聚焦于未知环境下无人机端到端目标追踪技术的研究，主要贡献包括：

- 1. 两阶段目标追踪框架：**提出了一种将目标搜索与目标跟踪相结合的两阶段框架。在未知环境中，无人机首先利用目标携带的信号装置进行粗略定位，然后采用传统搜索策略（如螺旋搜索、扇形搜索等）快速搜索目标。一旦检测到目标，即切换到基于强化学习的端到端跟踪模式，实现对目标的持续锁定和跟踪。这种框架充分利用了先验信息提高搜索效率，同时通过端到端学习保证了跟踪阶段的自主性和精确性。
- 2. 信号辅助的目标搜索：**针对未知环境下目标定位困难的问题，引入了信号检测作为先验信息辅助搜索。无人机通过搭载的信号接收装置（如无线电信号侦测、声学传感器等）检测目标发出的信号，据此初步估计目标方位。结合传统搜索算法，无人机能够在更小的范围内高效搜索，大幅缩短目标定位时间。这一创新有效解决了目标初始位置未知时的搜索难题。
- 3. 端到端强化学习跟踪：**在跟踪阶段，采用了端到端强化学习方法，使无人机能够直接从传感器数据（如图像、雷达、红外等）学习最优的控制策略。与传统的“感知-决策-控制”分阶段方法不同，端到端方法将整个跟踪过程视为一个连续的决策过程，通过深度神经网络直接将感知输入映射到控制输出。这意味着模型能够自动学习目标特征提取、状态评估与控制指令之间的最优映射，无需人工设计特征或状态空间，从而在复杂动态环境中实现更鲁棒的跟踪性能。本文设计了专门的强化学习网络结构和训练策略，使无人机在跟踪过程中能够自适应地调整飞行姿态和速度，保持对目标的稳定锁定。
- 4. 仿真验证与性能评估：**在仿真环境中对所提出的两阶段方法进行了全面测试，并与现有方法进行了对比评估。实验结果表明，本

文方法在目标定位时间、跟踪精度、抗干扰能力等方面均优于传统方法。特别是在目标发生快速机动或短暂消失的场景下，基于强化学习的端到端跟踪器能够快速重新捕获目标，展现出优越的鲁棒性和适应性。

1.4 论文结构安排

本文的其余部分安排如下：第2章对相关工作进行综述，包括无人机目标检测与跟踪技术的发展现状、未知环境下的搜索策略以及强化学习在无人机控制中的应用；第3章详细介绍未知环境下无人机目标搜索策略，包括基于信号检测的先验信息获取和传统搜索算法的应用；第4章阐述基于强化学习的端到端目标追踪方法，包括模型架构、训练策略以及与搜索阶段的融合机制；第5章给出系统实现细节和实验结果分析，验证所提方法的有效性；最后，第6章总结全文工作，并对未来研究方向进行展望。

● 2. 相关工作综述

2.1 无人机目标检测与跟踪技术综述

无人机目标检测与跟踪技术是实现自主追踪的核心。传统的方法通常将任务分为目标检测和目标跟踪两个子任务。目标检测是指在每一帧图像中识别并定位目标的过程，常用的技术包括基于特征的方法和基于深度学习的方法。早期基于特征的方法（如颜色直方图、HOG特征）在简单场景下有效，但在复杂环境下鲁棒性不足。随着深度学习的兴起，卷积神经网络（CNN）已成为目标检测的主流方法。以Faster R-CNN、YOLO等为代表的深度学习模型通过端到端训练，能够自动从数据中学习目标的多层次特征，大幅提高了检测准确率和实时性。在无人机视角下，目标的尺度、姿态和背景会随着无人机飞行不断变化，这对检测算法提出了更高要求。为此，研究者提出了针对无人机场景的优化算法，例如利用多尺度特征融合、数据增强和轻量级网络结构来提升检测模型在无人机视角下的泛化能力和速度。

目标跟踪则是在目标检测的基础上，对目标在连续帧中进行定位和关联。传统跟踪算法主要分为**生成式**和**判别式**两大类。生成式方法（如卡尔曼滤波、粒子滤波）通过目标模型预测下一帧的目标位置，但在目标外观变化时容易失效。判别式方法（如相关滤波、KCF）通过学习目标与背景的判别特征来定位目标，具有更好的鲁棒性。近年来，基于深度学习的跟踪算法成为研究热点。这类方法通常采用离线训练和在线跟踪两个阶段：在离线阶段，利用大量标注数据训练深度神经网络模型；在线阶段，将模型应用于实时视频流进行目标跟踪。其中，**孪生网络**

(Siamese Network) 是一种典型的端到端跟踪架构，它将目标模板和搜索图像分别输入两个共享权重的CNN，通过计算特征相似度来定位目标。该方法训练简单且速度快，在无人机跟踪领域表现出优异性能。此外，一些研究引入了**注意力机制**、**记忆机制**等深度学习技术，以解决目标遮挡和重新出现时的跟踪问题。总体而言，深度学习极大地推动了无人机目标跟踪技术的发展，但如何将检测与跟踪更紧密地结合，以及如何提升模型在未知环境下的适应能力，仍是当前研究关注的重点。

2.2 未知环境下的目标搜索策略

在未知环境中，由于缺乏目标的先验位置信息，无人机需要先进行搜索以发现目标。搜索策略的选择直接关系到目标发现的效率和无人机资源的利用。经典的搜索策略包括**确定型搜索**和**随机搜索**两大类。确定型搜索按照预定义的路径覆盖区域，例如**螺旋搜索**、**扫描线搜索**、**扇形搜索**等。这些方法简单易实现，但在复杂地形或目标分布未知的情况下，搜索效率有限。随机搜索则通过随机行走或随机采样探索环境，能够在一定程度上避免陷入局部最优，但搜索时间难以保证。为了提高搜索效率，研究者提出了许多优化算法，如**概率地图**方法，为环境中的每个单元分配目标存在的概率，并动态更新以指导无人机优先探索不确定性高的区域。此外，**多无人机协同搜索**通过信息共享和分工合作，可以显著缩短目标发现时间。例如，有研究将搜索地图划分为多个子区域，每架无人机负责一个区域的搜索，通过多机并行探索来加速目标定位。

近年来，**强化学习 (RL)** 在无人机搜索策略中也展现出潜力。强化学习通过让无人机与未知环境交互并获取奖励，自主学习最优的搜索路径，无需预先知道环境地图。例如，有学者利用深度Q网络 (DQN) 训练无人机在复杂环境中搜索目标，取得了优于人工策略的成果。多智能体强化学习 (MARL) 则被应用于多无人机协同搜索，通过集中训练-分布式执行，使多架无人机学会在未知区域协同决策，避

免重复搜索并更快发现目标。尽管如此，纯强化学习方法在搜索阶段往往需要大量试错，且目标定位精度有限。因此，本文考虑在搜索阶段结合信号检测等先验信息，以提高初始定位的准确性和效率。

2.3 强化学习在无人机控制中的应用

强化学习（Reinforcement Learning, RL）是一种机器学习范式，通过智能体与环境的反复交互，根据奖励信号不断调整策略以最大化累积回报。在无人机控制领域，强化学习近年来被广泛用于解决复杂决策问题，例如自主飞行、路径规划、避障、目标跟踪等。与基于模型的方法不同，RL方法不需要精确的环境模型，而是通过数据驱动的方式学习策略，这使得无人机能够在未知和动态的环境中自主适应。

在无人机目标跟踪任务中，RL方法的优势尤为突出。传统跟踪算法往往依赖于人工设计的特征和状态空间，难以全面描述复杂环境中的所有因素。而RL可以将跟踪过程视为一个连续的决策过程：无人机根据当前观测（如图像、目标距离等）选择飞行控制动作，环境根据无人机动作更新状态并给予奖励（例如接近目标时获得正奖励，丢失目标时获得负奖励）。通过不断试错和反馈，RL智能体能够学习到在各种情况下最优的控制策略。例如，有研究提出将无人机跟踪任务建模为马尔可夫决策过程（MDP），采用深度确定性策略梯度（DDPG）等算法训练无人机自主跟踪目标，结果在跟踪精度和稳定性上优于传统方法。端到端的深度RL方法更是将感知和决策融为一体，直接从原始传感器输入学习控制输出，避免了信息损失和误差累积。此外，RL还可以与仿真环境相结合，实现大规模低成本的数据收集和训练，为无人机跟踪策略的优化提供了有力工具。总之，强化学习为未知环境下的无人机目标跟踪提供了全新的解决思路，是实现自主智能控制的关键技术之一。

● 3. 未知环境下无人机目标搜索策略

3.1 基于信号检测的目标先验信息获取

在未知环境中开展目标搜索的首要挑战是缺乏目标的初始位置信息。传统搜索方法通常需要覆盖整个可能区域，这在大范围环境下效率低下。为此，本文引入**信号检测技术**作为先验信息来源。目标携带的信号装置可以是无线电信标、声学发射器或其他主动信号源，无人机通过搭载相应的传感器（如无线电接收机、麦克风阵列等）探测该信号。根据探测结果，无人机可以估计目标相对于自身的**粗略方位或距离**信息。例如，在无线电信号定位中，常用的方法包括**到达角度（AOA）测向**和**到达时间差（TDOA）定位**。AOA技术通过测量信号到达不同传感器阵列的角度差来确定信号源方向，而TDOA技术则通过测量信号到达多个基站的时间差来计算距离差，从而进行多站交会定位。这些技术已经在无人机侦测领域得到应用，能够实现对目标无人机的有效定位。在本研究中，无人机可利用单站AOA或双站TDOA等方法获取目标的方位信息，从而将搜索范围从全域缩小到目标可能存在的较小区域。

需要指出的是，信号检测结果往往存在误差，并且受环境噪声和干扰影响。因此，我们将信号检测视为一种**粗定位手段**，用于缩小搜索范围，但不作为精确位置的依据。通过融合信号检测与传统搜索策略，无人机可以在初始阶段快速接近目标区域，为后续精确定位奠定基础。

3.2 基于先验信息的目标搜索方法

在获取目标的粗略方位信息后，无人机将进入**目标搜索阶段**。本节结合先验信息和传统搜索算法，设计高效的搜索策略。首先，根据信号检测得到的目标方位，无人机规划一条朝向该区域的搜索路径。考虑到目标可能位于该区域内的任意位置，搜索策略需要保证在尽可能短的时间内发现目标。这里我们采用经典的**螺旋搜索**（也称螺旋式搜索）作为基本策略。螺旋搜索的基本思想是无人机从初始位置开始，围绕当前中心点进行螺旋式飞行，逐步扩大搜索半径，从而覆盖以初始估计点为中心的圆形区域。该方法具有实现简单、覆盖均匀的优点，非常适合用于在已知大致范围内搜索移动目标。

在执行螺旋搜索过程中，无人机持续开启传感器（如摄像头、雷达、红外等）对目标进行检测。一旦在任意时刻探测到目标（例如图像识别到目标或传感器捕获到目标信号），无人机即判定目标已被发现，并立即停止搜索模式，转而进入目标锁定和跟踪阶段。若在预定的搜索范围内仍未发现目标，无人机将根据信号检测结果调整搜索中心点，重新开始螺旋搜索或采用其他策略（如扇形搜索）以覆

盖更广区域。通过这种先验信息引导下的搜索，无人机避免了盲目的广域搜索，大幅提高了目标发现的概率和速度。

3.3 目标检测与锁定

当无人机在搜索过程中捕获到目标信号或识别到目标特征时，需要进行**目标锁定**，以确认目标并准备跟踪。目标检测通常采用前文所述的深度学习模型，如目标检测器或分类器，对传感器数据进行处理。在本系统中，目标检测与锁定主要发生在搜索阶段与跟踪阶段的切换点。一旦检测到目标，无人机将执行以下操作：

- 1. 确认目标：**对检测到的目标进行二次确认，以排除误报。例如，如果采用视觉检测，可以利用目标的运动特征或再次检测信号强度来验证目标身份。
- 2. 记录目标状态：**获取并记录目标相对于无人机的初始状态信息，包括位置、速度（如果可测）、外观特征等。这些信息将作为跟踪器的初始状态。
- 3. 切换模式：**将无人机控制模式从搜索切换到跟踪。在切换过程中，需要确保控制的平滑过渡，避免因模式切换导致无人机姿态剧烈变化或目标丢失。

目标锁定是整个流程的关键一步，其准确性直接影响后续跟踪性能。为此，本研究在检测环节融合了多源信息（如图像和信号），并采用高置信度阈值来减少误报。通过精心设计的锁定机制，无人机能够在发现目标的瞬间迅速准确地锁定目标，为端到端跟踪算法提供可靠的初始条件。

● 4. 基于强化学习的端到端目标追踪方法

4.1 强化学习基础与无人机控制框架

强化学习通过让无人机作为智能体与环境交互，学习最优的控制策略。在本研究的跟踪阶段，我们将目标跟踪任务形式化为一个**马尔可夫决策过程（MDP）**，包括状态空间、动作空间、奖励函数等要素。

- **状态空间 (State Space)**：状态空间由无人机和目标的相关观测构成。例如，可以包括目标在图像中的位置（边界框坐标）、无人机自身的位置和速度、目标与无人机的相对距离和角度、环境信息（如风速）等。状态的设计需尽量全面，以反映跟踪过程中的重要因素。
- **动作空间 (Action Space)**：动作空间定义了无人机可执行的控制指令。在本系统中，无人机通常采用**速度控制**或**姿态控制**作为动作。例如，动作可以定义为无人机在机体坐标系下的三维速度增量（前后、左右、上下），或者为航向、俯仰和滚转角的变化。动作空间可以是连续的（对应于直接控制指令），也可以是离散的（如选择预设的飞行动作）。本文采用连续动作空间，以实现精细的控制。
- **奖励函数 (Reward Function)**：奖励函数用于指导智能体学习目标跟踪策略。奖励的设计应反映跟踪任务的目标，即让无人机尽可能稳定地跟踪目标。典型的奖励包括：当目标保持在视野中心时给予正奖励，目标偏离视野时给予负奖励，成功跟踪一段时间后给予额外奖励等。此外，为避免无人机飞出范围或碰撞，可以在奖励中加入相应的惩罚项。奖励函数需要精心设计，以平衡不同目标并引导智能体学习期望的行为。

基于上述MDP模型，我们采用**深度强化学习**算法来训练无人机跟踪策略。与传统的基于规则的控制方法不同，RL策略通过大量试错学习，能够自动适应复杂环境中的各种情况。在本研究中，我们重点考虑了**端到端学习**的方法，即让神经网络直接从原始观测（如图像像素）学习到控制输出，无需人工提取特征或设计状态。端到端方法具有更强的适应性和泛化能力，但同时也面临训练难度大、样本需求量高的挑战。为此，我们采用了先进的深度RL算法和训练技巧，以提高学习效率和策略稳定性。

4.2 端到端强化学习跟踪模型设计

为了实现端到端的目标跟踪，我们设计了一个**深度神经网络策略模型**。该模型以无人机的传感器观测为输入，直接输出无人机的控制指令。具体而言，模型可以采用**卷积神经网络 (CNN) + 全连接层**的结构。CNN部分负责处理图像等高维感知数据，提取目标的特征；全连接层部分则将提取的特征与其他状态信息融合，输出对应的控制量。例如，在基于视觉的跟踪中，模型可以输入连续几帧的图像序列，通过CNN提取目标的时序特征，再经过全连接层预测下一时刻无人机的速度或舵机指令。

在训练阶段，我们使用**深度确定性策略梯度（DDPG）**算法及其变体。DDPG是一种结合了策略梯度和价值函数逼近的连续动作空间RL算法，它采用Actor-Critic架构，并通过经验回放和目标网络来稳定训练。在本研究中，我们对DDPG进行了改进，以适应无人机跟踪任务的复杂性。例如，我们引入了**双Critics**和**三Critics**机制，即同时维护多个价值网络估计Q值，通过去除最大值后取平均的方式，减少高估偏差，提高学习稳定性。此外，我们还探索了**多阶段策略**，将跟踪过程分为**粗跟踪**和**精跟踪**两个子阶段，分别训练不同的策略网络，以兼顾跟踪速度和精度。

为了加快训练速度并提高策略的鲁棒性，我们采用了**仿真训练+ 实机微调**的范式。首先，在逼真的仿真环境中（如Gazebo、AirSim等）训练策略模型，通过大量仿真样本让无人机学习在各种环境下跟踪目标的能力。仿真环境可以提供丰富的场景变化和随机性，同时避免实际飞行风险和成本。在仿真训练达到一定性能后，将策略模型部署到真实无人机上，进行实地飞行测试。在实机测试中，我们收集真实环境下的数据，用于对模型进行微调（fine-tuning），以补偿仿真与现实之间的差距（Sim-to-Real gap）。通过这种迁移学习方式，可以显著提升模型在真实世界中的表现。

4.3 策略网络与价值网络设计

在DDPG算法中，**Actor网络**（策略网络）负责根据当前状态选择动作，**Critic网络**（价值网络）负责评估当前状态和动作的价值，以指导Actor网络的更新。针对无人机跟踪任务，我们对网络结构进行了专门设计。

Actor网络：Actor网络的输入是当前状态，输出是连续的控制指令。在本研究中，我们采用**卷积+全连接**的混合结构。输入图像首先经过若干卷积层和池化层，提取目标的特征表示；然后，这些特征与其他状态信息（如无人机姿态、相对距离等）拼接，输入一系列全连接层；最后，输出层生成无人机的控制量（例如速度的三个分量）。为了提高策略的平滑性，我们可以在输出层后增加一个积分器，将网络输出的控制增量作用于当前控制量，从而避免剧烈抖动。此外，我们还尝试了**多模态输入**，即在Actor网络中同时融合视觉和信号传感器信息，以提高策略的鲁棒性。例如，当目标在图像中短暂消失时，网络仍可依据信号强度等信息调整飞行，避免完全丢失目标。

Critic网络：Critic网络的输入同样是当前状态，输出是对应动作的价值Q值估计。为了提高价值估计的准确性，我们采用了**双Critic**或**三Critic**的结构，即训练多个

独立的Critic网络，并在更新时使用这些网络输出的最小值来作为目标Q值，从而减少高估偏差。此外，我们还引入了**经验回放**机制，将每一步交互存储在缓冲区中，训练时从中随机采样小批量数据，以打破数据相关性，提高训练稳定性。

4.4 训练方法与算法优化

在训练过程中，我们采用了多种技巧来加速收敛和提升最终性能。首先，我们设计了**奖励塑造（Reward Shaping）**策略，在原始奖励基础上引入一些引导性奖励，帮助智能体更快地理解任务目标。例如，在训练初期，给予无人机**接近目标**的额外奖励，即使目标尚未完全进入视野。随着训练进行，逐渐减弱这些引导奖励，使智能体最终学会仅基于原始奖励完成任务。其次，我们采用了**课程学习（Curriculum Learning）**的方法，从简单到复杂逐步增加训练难度。例如，初始训练时使用静止目标或低速运动目标，让智能体掌握基本的跟踪技能；随后逐步提高目标的运动速度和机动性，以及增加环境干扰（如光照变化、障碍物等），使智能体学会应对更复杂的情况。这种渐进式训练有助于避免智能体在复杂环境中过早陷入失败，从而提高学习效率。

此外，我们还利用**多智能体强化学习**的思想，将跟踪任务拆分为多个子任务，由不同的智能体（策略模块）协同完成。例如，可以设计一个**搜索智能体**和**跟踪智能体**：搜索智能体负责在没有目标信息时探索环境，跟踪智能体负责在有目标时维持跟踪。通过让两个智能体分别学习和协作，可以实现从搜索到跟踪的平滑过渡。在实际训练中，我们使用层次化强化学习（HRL）框架，将高层的任务切换决策交给一个元策略，低层的跟踪策略由专门的子策略执行，从而构建一个层次化的端到端跟踪系统。

最后，在算法层面，我们引入了**熵正则化**等探索策略，以防止策略过早收敛到局部最优。通过在目标函数中加入熵项，鼓励智能体在训练早期探索多样化的动作，从而发现更优的跟踪策略。同时，我们采用**优先经验回放（Prioritized Experience Replay）**，给予那些包含重要信息（如目标重新出现、跟踪失败等）的经验更高的采样概率，加快对关键情况的学习。这些优化措施共同作用，使得无人机跟踪策略在仿真和真实环境中均取得了良好的性能。

● 5. 系统实现与实验验证

5.1 系统架构与实现细节

为了验证所提出的两阶段目标追踪方法，我们构建了完整的仿真实验平台和原型系统。系统架构包括**无人机平台**、**传感器子系统**、**计算与控制单元**和**地面站**四大部分。无人机平台采用小型四旋翼无人机，搭载机载计算单元（如高性能嵌入式计算机）用于实时处理传感器数据并运行跟踪算法。传感器子系统包括**视觉传感器**（高清摄像头）、**信号接收器**（无线电信号检测模块）和**惯性导航系统**（IMU、GPS等）。视觉传感器用于目标检测与跟踪，信号接收器用于在搜索阶段捕捉目标发出的信号，惯性导航系统用于无人机自身的定位与姿态估计。计算与控制单元运行着本研究的核心算法，包括传统搜索策略、深度学习检测模型和强化学习跟踪策略等。地面站用于远程监控和日志记录，方便对实验过程进行分析和调试。

在软件实现上，我们采用了模块化设计。目标检测模块基于预训练的深度学习模型（如YOLOv5或Faster R-CNN），使用TensorRT等推理库进行加速，以保证在嵌入式平台上的实时性。强化学习跟踪模块则使用PyTorch或TensorFlow实现DDPG算法，并通过加载预先训练好的模型进行在线推理。搜索策略和控制逻辑由无人机控制脚本实现，根据当前阶段（搜索或跟踪）调用相应模块。整个系统在ROS（Robot Operating System）环境下集成，各个模块通过消息传递进行通信，从而保证系统的灵活性和可扩展性。

5.2 实验环境与数据集

由于实际飞行测试受环境和成本限制，我们主要在仿真环境中进行大规模实验，并选取部分场景进行实地验证。仿真环境使用Gazebo搭建，模拟了包括城市、野外在内的多种复杂场景，以及不同的光照和天气条件。仿真中，目标可以设置为地面移动车辆、人员或其他无人机，其运动轨迹由预定义路径或随机行为生成。我们设计了多组实验来测试不同因素对系统性能的影响，例如目标的初始位置随机性、目标的运动速度和机动模式、信号干扰的存在与否等。


在数据方面，我们采集了**无人机视角下的目标跟踪数据集**，用于训练和评估检测与跟踪算法。数据集包含多种场景下目标在无人机摄像头中的图像序列，以及对应的目标标注框。数据集的构建考虑了不同高度、俯仰角和光照条件，以提高模型的泛化能力。对于强化学习训练，我们在仿真中生成了大量的交互数据，包括无人机状态、控制动作和奖励等信息。这些数据用于训练跟踪策略，并通过迁移学习技术应用到真实无人机上。

5.3 性能评估指标

为了全面评估系统性能，我们采用了多个指标，包括：

- **目标定位时间**：从任务开始到目标首次被成功发现的时间。该指标反映搜索阶段的效率。
- **跟踪精度**：跟踪过程中目标在图像中的位置误差（像素距离）或相对距离误差。该指标衡量跟踪阶段的准确度。
- **跟踪持续时间**：目标在被发现后，无人机能够持续跟踪的时间长度。该指标反映跟踪策略的稳定性。
- **跟踪成功率**：在多次实验中，成功完成跟踪任务（例如跟踪直到目标离开场景或任务结束）的比例。该指标综合反映系统的鲁棒性。
- **平均跟踪误差**：在整个跟踪过程中位置误差的平均值，用于量化跟踪精度。
- **跟踪重获时间**：当目标短暂丢失后，无人机重新捕获目标所需的时间。该指标反映系统应对遮挡等挑战的能力。

通过这些指标，我们可以对不同方法进行定量比较，并分析所提方法在各种情况下的表现。



5.4 实验结果分析

实验结果表明，本文提出的**两阶段目标追踪方法**在总体性能上优于传统方法。首先，在目标搜索阶段，由于引入了信号检测辅助，无人机的初始定位时间显著缩短。相比不利用信号信息的方法，本文方法能够在更短的时间内发现目标，尤其在目标初始距离较远或环境复杂时优势更加明显。这是因为信号检测将搜索范围缩小，避免了无人机进行大范围无效搜索。




图2：不同初始目标距离下的定位时间对比

其次，在目标跟踪阶段，基于强化学习的端到端跟踪器展现了出色的跟踪精度和鲁棒性。与传统基于规则或视觉伺服的方法相比，RL策略能够自适应地调整飞行姿态以保持对目标的稳定跟踪。在目标作匀速直线运动的情况下，各方法都能较好地跟踪；但当目标进行急转弯或加速机动时，传统方法往往出现较大的跟踪误差甚至丢失目标，而RL策略通过学习的经验能够预判目标运动并及时调整，跟踪误差明显更低。此外，当目标被短暂遮挡或离开视野后，RL策略能够根据之前的学习结果预测目标可能出现的位置，从而快速重新捕获目标，这体现在更短的跟踪重获时间上。




图3：目标作急转弯机动时的跟踪误差对比

我们特别对比了**纯视觉跟踪方法**和**视觉+信号融合跟踪方法**。结果显示，在信号检测有效时，融合方法能够提供额外的目标距离信息，帮助无人机更好地维持与目标的距离。当视觉跟踪因目标变远或光照变化而变得困难时，信号强度信息可以辅助无人机判断目标是否仍在附近，从而及时调整飞行策略。这种多模态融合使得系统在复杂环境下的跟踪成功率得到进一步提高。

最后，我们进行了多组不同场景的实验，包括城市环境、开阔野外和夜间低光照环境等。结果表明，所提方法在多种场景下均能保持较高性能，体现了良好的泛化能力。在城市环境中，无人机能够成功跟踪移动车辆，并避开楼宇遮挡造成的跟踪中断；在野外环境中，无人机可以跟踪奔跑的人或动物，即使目标短暂进入树林也能重新发现；在夜间低光照条件下，由于红外传感器和信号检测的作用，无人机依然能够锁定目标，只是跟踪精度略有下降。总体而言，实验验证了本文方法在未知环境下实现目标端到端追踪的有效性和鲁棒性。




图4：不同场景下的任务跟踪成功率对比

● 6. 结论与展望

6.1 研究工作总结

本文针对未知环境下无人机目标追踪的难题，提出了一种**基于强化学习的端到端目标追踪技术**。该技术通过将任务分解为搜索和跟踪两个阶段，充分利用目标携带信号装置的先验信息，实现了从目标粗定位到精确跟踪的无缝衔接。在搜索阶段，采用信号检测辅助传统搜索策略，大幅提高了目标发现效率；在跟踪阶段，利用端到端强化学习训练无人机自主跟踪策略，显著提升了跟踪精度和鲁棒性。仿真与实验结果表明，所提方法在目标定位时间、跟踪稳定性、抗干扰能力等方面均优于传统方法，为未知环境下无人机自主执行目标追踪任务提供了有效解决方案。

6.2 未来研究方向

尽管本文取得了一定成果，但仍有许多值得进一步研究的方向：

- **多目标与多无人机协同：**当前研究主要针对单目标、单无人机场景。未来可以扩展到多目标跟踪或多无人机协同跟踪的场景。这涉及到目标分配、协同决策、冲突避免等更复杂的问题，需要更高级的算法和通信机制支持。
- **更高维度的感知融合：**本研究融合了视觉和信号两种模态的信息。未来可以引入更多传感器，如激光雷达、红外成像、声学阵列等，实现多模态感知融合。多模态信息能够提供互补的环境信息，提高目标定位和跟踪的鲁棒性，特别是在极端天气或夜间等条件下。
- **更强的自主性与智能：**随着人工智能技术的发展，可以进一步提升无人机系统的自主决策能力。例如，引入元学习或迁移学习，使无人机能够在新环境下快速适应；利用深度强化学习结合强化学习规划，实现更长远的任务规划。此外，还可以将强化学习与SLAM（同步定位与地图构建）技术结合，让无人机在未知环境中同时完成自身定位和目标跟踪，实现真正的全自主导航。
- **实时性与安全性的权衡：**在追求高性能的同时，必须考虑算法的实时性和安全性。未来研究应优化算法复杂度，使其在嵌入式平台上也能实时运行，并确保无人机的飞行安全。这可能涉及轻量化模型设计、硬件加速以及故障检测与安全策略的制定。
- **法规与伦理考量：**随着无人机应用的普及，相关的法规和伦理问题也日益重要。未来研究应关注无人机目标追踪技术在隐私保护、空域管理、避障规则等方面的合规性，以确保技术在实际应用中能够安全、合法地运行。

综上所述，未知环境下基于强化学习的无人机端到端目标追踪技术是一个充满挑战但也极具前景的研究方向。通过持续深入的研究和技术创新，我们有望见证无人机在更多复杂场景下实现自主、高效、安全的目标追踪，为各行业带来革命性的变化。